

✦ Hidden Markov Models - Uma Breve Introdução

José Roberto S. de Moura

Coordenador do Núcleo de Pesquisa e Desenvolvimento da GAVB

Agenda

Motivação

Modelos de Markov

Cadeias de Markov

Exemplos

Implementação

Hidden Markov Models

Motivação

Alguns Exemplos de Uso



Applied Soft Computing
Volume 60, November 2017, Pages 229-240



Energy Economics
Volume 32, Issue 6, November 2010, Pages 1507-1519



Multivariate time series anomaly detection: A framework of Hidden Markov Models

Jinbo Li^a, Witold Pedrycz^{a,b,c,d}, Iqbal Jamal^d

April 2017, 13(2): 757-773. doi: 10.3934/jimo.2016045

Hidden Markov models with threshold effects and their applications to oil price forecasting

Dong-Mei Zhu¹, Wai-Ki Ching², Robert J. Elliott^{3,4}, Tak-Kuen Siu⁵ and Lianmin Zhang⁶

Hidden Markov Models for failure diagnostic and prognostic

Publisher: IEEE

Cite This

PDF

D. A. Tobon-Mejia¹, K. Medjaher², N. Zerhouni³, G. Tript⁴ All Authors

24
Paper
Citations

1058
Full
Text Views

Hidden Markov Models for the Prediction of Impending Faults

Publisher: IEEE

Cite This

PDF

Abdenour Soualhi¹, Guy Clerc², Hubert Razik³, Mohamed El badaoui⁴, François Guillet⁵ All Authors

36
Paper
Citations

1362
Full
Text Views

SuperAccess Article

Clustering Multivariate Time Series Using Hidden Markov Models

by S. Shima Ghassampon^{1,2,3}, F. Federico Girani² and A. Anthony Maeder^{1,2}

¹ School of Computing, Engineering and Mathematics, University of Western Sydney, Campbelltown, NSW 2751, Australia

² Centre for Health Research, University of Western Sydney, Campbelltown, NSW 2751, Australia

³ Author to whom correspondence should be addressed.

Int. J. Environ. Res. Public Health 2014, 11(3), 2741-2763. https://doi.org/10.3390/ijerph110302741

Modelos de Markov

Modelos de Markov

Os **Modelos de Markov** são **processos estocásticos** nos quais o **estado da variável aleatória no próximo instante de tempo** depende apenas da saída da variável no instante atual.

O Princípio de Markov

Princípio de Markov

Um **processos estocástico** $S = \{R_1, R_2, \dots, R_n\}$, de estados $\{R_i\}_{i=1}^n$, será um processo de Markov se respeitar

$$Pr(R_{n+1} | R_1, \dots, R_n) = Pr(R_{n+1} | R_n),$$

também chamada de **propriedade de Markov**.

Isso significa que o estado em que estaremos no próximo instante de tempo, depende apenas do estado atual.


Cadeias de Markov

O **Modelo de Markov** mais simple que nós temos são as **Cadeias de Markov**: processos de Markov com **tempo discreto**.

Dado um **conjunto de observáveis** $(x_1 \dots x_n)$, que obedecem o **princípio de Markov**, então a **distribuição de probabilidades conjunta** para N observações fica


$$Pr(x_1 \dots x_N) = Pr(x_1) \prod_{n=2}^N Pr(x_n | x_{n-1})$$

Representação Gráfica



Exemplo01: Moedas Justas

Vamos considerar o lançamento de uma moeda justa, o que significa que temos dois estados possíveis Head (H) e Tail (T). Como a moeda é justa, podemos transitar entre um estado e outro com uma probabilidade de 0.5, assim como se manter no atual.




Matriz de Transição:

$$A = \begin{bmatrix} P_{HH} & P_{HT} \\ P_{TH} & P_{TT} \end{bmatrix} = \begin{bmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{bmatrix}$$

Exemplo 02: Modelo Epidemiológico

O modelo SIR (Suscetível - Infectado - Recuperado), é um dos modelos epidemiológicos mais simples que temos. Neste exemplo vamos considerar que não existe imunização, ou seja, após a pessoa se recuperar da doença, ela volta para o estado de suscetível. O modelo está exemplificado no diagrama abaixo.



Matriz de Transição:

$$A = \begin{bmatrix} P_{SS} & P_{SI} & P_{SR} \\ P_{IS} & P_{II} & P_{IR} \\ P_{RS} & P_{RI} & P_{RR} \end{bmatrix} = \begin{bmatrix} 0.9 & 0.1 & 0.0 \\ 0.0 & 0.7 & 0.3 \\ 1.0 & 0.0 & 0.0 \end{bmatrix}$$

Ir para a Implementação

Hidden Markov Models

MC de 2ª: MC onde o próximo estado depende tanto do atual, quanto do anterior

$$Pr(x_1 \dots x_n) = Pr(x_1)Pr(x_2|x_1) \prod_{n=3}^N Pr(x_n|x_{n-1}, x_{n-2}).$$

Nesse caso, temos que a d.p. conjunta de X_n , dados X_{n-1} e X_{n-2} , é independente de todas as demais observações.

Se tivermos que as observações são **variáveis discretas**, tendo K estados, então $Pr(X_n|X_{n-1})$ de uma MC de 1ª ordem, será especificada por um conjunto de $K - 1$, para cada um dos K estados de X_{n-1} , o que nos dá um total de $K(K - 1)$ **parâmtros**

Extendendo para uma MC de ordem M e usando o mesmo raciocínio que o anterior, chegamos a um número de


$$K^{M-1}(K - 1)$$

parâmetros, ou seja, temos um **crescimento exponencial**.

Solução para M grande: Introdução de **variáveis latentes**.

Para cada observação x_n , associamos uma variável latente z .

Obs.: Quando as variáveis latentes formam uma MC de 1ª, elas formam uma classe de modelos chamada **modelos de espaço de estados**.



Exemplo: Jogo de Moedas Viciadas

Vamos considerar a situação em que temos duas moedas viciadas: M_1 e M_2 .

- ✱ $P(M_1) = P(M_2) = 0.5$
- ✱ M_1 : $P(H) = 0.7$ e $P(T) = 0.3$
- ✱ M_2 : $P(H) = 0.2$ e $P(T) = 0.8$

